

```
In [2]: import numpy as np
import scipy.stats as sps
import matplotlib.pyplot as plt
import pylab
%matplotlib inline
```

Вывод формулы $E(N_t|N_s)$

Воспользуемся линейностью условного матожидания:

$$E(N_t|N_s) = E([N_t - N_s]|N_s) + E(N_s|N_s) = E([N_t - N_s]|N_s) + N_s$$

Известно что

$$(N_t - N_s) \sim \text{Pois}(\lambda(t - s))$$

$(N_t - N_s)$ независимо с N_s

$$\text{Значит, } E(N_t|N_s) = E(N_t - N_s) + N_s = \lambda(t - s) + N_s$$

```
In [3]: # данные из файла
real_lambda_ = 1/95
t_0 = 500
t = 100000

data = np.loadtxt('6.csv.xls', delimiter=',', skiprows=3)
```

Распределение, сопряженное к экспоненциальному - $\Gamma(\alpha, \beta)$. Тогда байесовская оценка параметра λ равна $\frac{n+\alpha}{\beta+\sum_{i=1}^n \xi_i}$,

где ξ_i - время между i -ым и $(i + 1)$ -ым выходами из строя сервера.


Подберём параметры сопряженного распределения, для этого рассмотрим график плотности гамма распределения:

```

In [4]: alpha_ = np.array([1, 1, 1, 2])
        beta_ = np.array([1, 2, 4, 1])

        x = np.linspace(0, 20, 1000)
        plt.figure(figsize=(12, 8))
        for i in range(4):
            plt.plot(x, sps.gamma.pdf(x, a=beta_[i], scale=1/alpha_[i]), linewidth=1.5,
                    label=r'$\alpha = $' + str(alpha_[i]) + r'$ \beta = $' + str(beta_[i]))
        plt.xlim(0, 15)
        plt.ylim(0, 0.5)
        plt.xlabel('$t$', fontsize=20)
        plt.ylabel('$q(t)$', fontsize=20)
        plt.title('Плотность', fontsize=20)
        plt.legend(fontsize=13)
        plt.grid()
        plt.show()

```



Поскольку в начальный момент времени мы ничего не знаем о параметре λ , то нам не подходят параметры Гамма распределения, при которых образуется явный "горб" над каким-то конкретным числом. Нам следует этого избегать.

Значит, нужно брать параметр $\alpha = 1$, а за параметр β можно взять 2, при котором график плотности выглядит не очень крутым.

```

In [5]: alpha = 1
        beta = 2

        # функция вычисляет действительное количество вышедших из строя серверов
        # к моменту времени t, по данным из файла
        def count_real_num(t):
            return np.sum(data <= t)

        reality = []      # реальное число вышедших из строя серверов
        prediction = []   # предсказанное число вышедших из строя серверов (по известному lambda)
        time = np.arange(0, t+t_0, t_0)
        for s in time:
            reality.append(count_real_num(s))
            prediction.append(count_real_num(s) + real_lambda_*(t-s))

```

Предскажем количество серверов, оценив λ :

```

In [6]: xi = np.zeros(data.size)
        xi[1:] = data[:data.size - 1]
        xi = data - xi

        lambda_ = np.zeros(t//t_0 + 1)
        for i in range(t//t_0 + 1):
            lambda_[i] = (reality[i] + alpha) / (xi.cumsum()[reality[i] - 1] + beta)

        result = lambda_ * (t - time) + reality

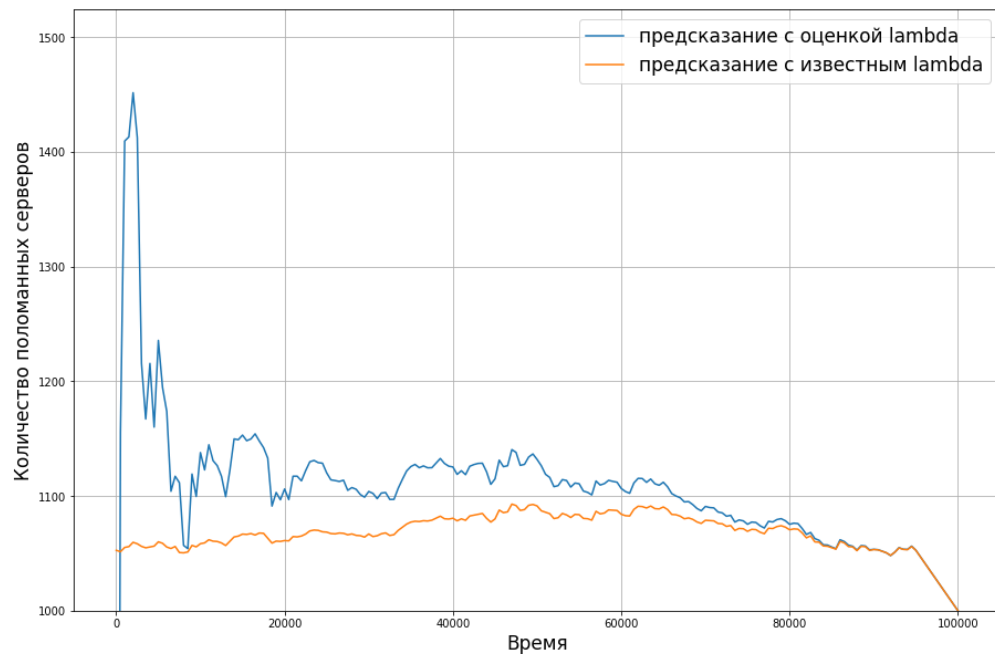
```

Вывод предсказания того, сколько серверов нужно докупить к моменту времени t:

```
In [7]: for i in range(time.size):  
        print ("Время = %d : количество серверов = %d" % (time[i], result[i]))
```


[illegible]

```
In [8]: plt.figure(figsize=(15,10))
plt.plot(time, result, label='предсказание с оценкой lambda')
plt.plot(time, prediction, label='предсказание с известным lambda')
plt.ylabel("Количество поломанных серверов", fontsize=17)
plt.xlabel("Время", fontsize=17)
plt.ylim((1000))
plt.legend(fontsize=17)
plt.grid()
plt.show()
```



Построим график зависимости модуля разности значения параметра λ и его оценки от времени.

```
In [9]: plt.figure(figsize=(15,10))
plt.plot(time, abs(lambda_ - real_lambda_))
plt.ylabel(r'$|\lambda - \hat{\lambda}|$', fontsize = 17)
plt.xlabel("Время", fontsize=17)
plt.grid()
plt.show()
```



Вывод:

Сначала оценка плохо приближает параметр λ , но с увеличением количества считанных данных ситуация улучшается и оценка сходится.